

基于机器学习的物流网络应急调度优化设计

摘要

电商物流网络由物流场地和物流场地之间的运输线路组成，如果能够预测各物流场地及线路的包裹数量，管理者将可以提前安排运输、分拣等计划，本文通过解决以下问题，对物流网络进行调运及优化。

针对问题一，要求建立线路货量的预测模型，对 2023-01-01 至 2023-01-31 期间每条线路每天的货量进行预测。首先，我们将所给的数据通过 Matlab 进行数据提取，得到各个路线每日的货物情况，再建立**基于深度 AR 神经网络的预测模型**，得到各路线在 2023-01-01 至 2023-01-31 期间的货物流通情况，其中在**2023 年 1 月 31 号，DC14→DC10 路线上共有 62850 件货物**。

针对问题二，要求在 DC5 站点关闭时，建立数学模型，使得所有包裹尽可能的正常流转，以及 DC5 关停前后变化的线路尽可能少，且保持各条线路的负荷尽可能均衡。首先，我们引入线路包裹数量作为决策变量，引入线路变化函数、工作负荷函数以及非正常流转天数作为目标函数，引入最大限制约束条件、站点损坏约束条件，建立**多目标优化模型**，通过**遗传算法**进行求解，最终得到新的线路货物量分布，其中**一共有 68 条路线的货物量运输情况发生了改变，其平均负荷率在百分之 20 附近波动**。

针对问题三，要求在关闭 DC9 站点，并且能够每日对站点网络进行动态分配，使得所有的包裹尽可能的正常流转，并且改变的线路数尽可能少，以及各条线路的工作负荷尽可能均衡。首先，我们在模型二的基础上引入新的决策变量，代表各路线是否开放，并且优化了问题二中的部分约束条件以及目标函数，引入货物总量的动态约束，建立了**多目标动态规模模型**，使用**遗传算法**进行求解，最终得到各路线每日货物量情况，其中**一共新增了包括 22-2 在内的 4 条线路，一共有 116 条线路货物量运输情况发生改变，其平均负荷率在百分之 2 附近波动**。

针对问题四，要求对该网络的不同物流场地及线路的重要性进行评价，并讨论新增物流场地的处理能力以及新增线路的运输能力。首先，有些网络在以前很火爆，但近期逐渐衰败，为了使模型具有时效性，我们选择在 2022 年 6 月到 2022 年 12 月期间对各线路的货物运输总量、累计开启时间、最大运输能力、最长连续开启时间、最长连续关闭时间，五个方面进行统计，对各站点的连接线路个数、最大承载能力、最大发送能力、累计承载数量和累计发送数量五个方面进行统计，建立**基于 TOPSIS 熵权法的评价模型**对站点和路线进行评价，得出**线路的前三名为 14-8、17-10、22-4，站点的前三名为 DC10、DC7、DC8 的结论**，之后根据预测结果以及评价结果，决定在 DC10 与 DC8 附件建立新站点，并与二者相连通，其处理能力以及线路运输能力为二者最大值的平均值，并通过讨论证明了我们的网络具有相当高的鲁棒性。

本文还对模型优缺点进行评价，说明了模型的适用情况。最后对模型进行横向推广和纵向推广，证明了模型的普适性。

关键词：深度 AR 神经网络；多目标优化模型；遗传算法；TOPSIS 熵权法

目录

基于机器学习的物流网络应急调度优化设计 1

一、 问题重述 1

 1.1 背景知识 1

 1.2 相关数据 1

 1.3 具体问题 1

 1.3.1 问题一 1

 1.3.2 问题二 1

 1.3.3 问题三 1

 1.3.4 问题四 1

二、 问题分析 1

 2.1 研究现状综述 1

 2.2 问题的总体分析和解题思路 2

 2.3 对问题的具体分析 2

 2.3.1 对问题一的具体分析 2

 2.3.2 对问题二的具体分析 2

 2.3.3 对问题三的具体分析 2

 2.3.4 对问题四的具体分析 2

三、 模型假设 3

四、 符号说明 3

五、 模型的建立与求解 4

 5.1 问题一的分析与求解 4

 5.1.1 对问题的分析 4

 5.1.2 数据处理与可视化分析 4

 5.1.3 基于深度 AR 神经网络的货物量预测模型的建立与求解^[3] 5

 5.2 问题二的分析与求解 7

 5.2.1 多目标优化模型的建立 7

 5.2.2 遗传算法的原理 8

 5.2.3 模型求解 9

 5.2.4 优化模型合理性与灵敏度分析 10

 5.3 问题三的分析与求解 10

5.3.1 多目标动态规划模型的建立	11
5.3.2 基于遗传算法的动态规划模型求解 ^[4]	12
5.3.3 改进后的优化模型灵敏度分析	13
5.4 问题四的分析与求解	13
5.4.1 数据整理	14
5.4.2 基于 TOPSIS 熵值法的评价模型原理	14
5.4.3 评价模型的求解	15
5.4.4 新增站点及线路的讨论	16
5.4.5 网络的鲁棒性分析	16
六、模型的评价和推广	16
6.1 模型的优点	16
6.2 模型的缺点	16
6.3 模型的推广	17
6.3.1 横向推广	17
6.3.2 纵向推广	17
七、参考文献	18
八、附录	19

一、问题重述

1.1 背景知识

电商物流网络由物流场地和物流场地之间的运输线路组成，如果能够预测各物流场地及线路的包裹数量，管理者将可以提前安排运输、分拣等计划从而降低运营成本，提高运营效率。特别地，在某些场地临时或永久停用时，基于预测结果和各个物流场地的处理能力及线路的运输能力，设计物流网络调整方案，将会大大降低物流场地停用对物流网络的影响，保障物流网络的正常运行。

1.2 相关数据

1.2021-2022 年各路线的历史物流情况。（附件 1 表单 1）

1.3 具体问题

1.3.1 问题一

建立线路货量的预测模型，对 2023-01-01 至 2023-01-31 期间每条线路每天的货量进行预测，并在提交的论文中给出线路 DC14→DC10、DC20→DC35、DC25→DC62 的预测结果。

1.3.2 问题二

要求在 DC5 站点关闭时，建立数学模型，使得所有包裹尽可能的正常流转，以及 DC5 关停前后变化的线路尽可能少，且保持各条线路的负荷尽可能均衡。

1.3.3 问题三

要求在关闭 DC9 站点，并且能够每日对站点网络进行动态分配，使得所有的包裹尽可能的正常流转，并且改变的线路数尽可能少，以及各条线路的工作负荷尽可能均衡。

1.3.4 问题四

求对该网络的不同物流场地及线路的重要性进行评价，并讨论新增物流场地的处理能力以及新增线路的运输能力。

二、问题分析

2.1 研究现状综述

孟庆年^[1]通过引入了半参数补偿最小二乘方法,将模型误差用非参数来加以弥补,提高了模型的精度。对比最小二乘方法、总体最小二乘方法和补偿最小二乘方法对时间序列的分析和预报结果。实验表明,补偿最小二乘方法所建立的模型对时间序列的分析和预报效果最好。

薛亚龙^[2]为了提升数据情报侦查运算挖掘分析的准确性和精确性，引入基于遗传算法的数据情报侦查方法研究范式。以遗传算法数据情报侦查的内涵与属性为研究逻辑起点，提出遗传算法数据情报侦查的平台设计方案，构建遗传算法数据情报侦查的流程模型，探讨遗传算法数据情报侦查的应用方法。

目前有许多关于预测以及优化类的研究文献，但是对于电商网络结构的应急调度优化问题的相关研究却很少，研究如何预测货物数量并且优化电商网络的结构具有一定价值。

2.2 问题的总体分析和解题思路

本文主要研究电商网络结构的应急优化问题，针对此问题，我们主要分成四个小问进行研究，根据本文的研究思路，总体思路流程图如图 1

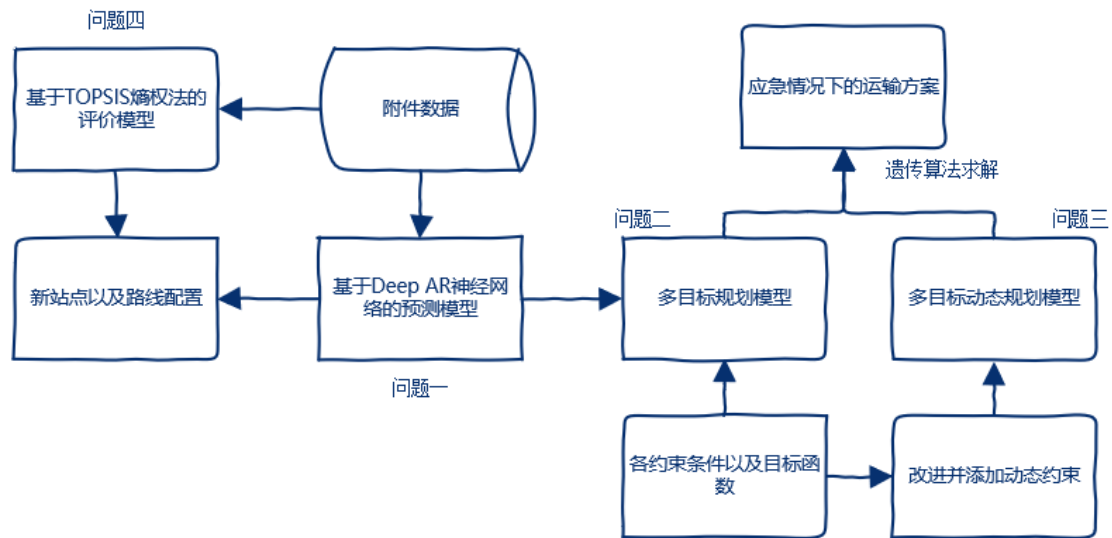


图 1 总体思路流程图

2.3 对问题的具体分析

2.3.1 对问题一的具体分析

要求建立线路货量的预测模型，对 2023-01-01 至 2023-01-31 期间每条线路每天的货量进行预测，并给出线路 DC14→DC10、DC20→DC35、DC25→DC62 的预测结果。首先，我们将所给的数据通过 Matlab 进行数据提取，得到各个路线每日的货物情况，再建立基于深度 AR 神经网络的预测模型，得到各路线在 2023-01-01 至 2023-01-31 期间的货物流通情况。

2.3.2 对问题二的具体分析

要求在 DC5 站点关闭时，建立数学模型，使得所有包裹尽可能的正常流转，以及 DC5 关停前后变化的线路尽可能少，且保持各条线路的负荷尽可能均衡。首先，我们引入线路包裹数量作为决策变量，引入线路变化函数、工作负荷函数以及非正常流转天数作为目标函数，引入最大限制约束条件、站点损坏约束条件，建立多目标优化模型，通过遗传算法进行求解，最终得到新的线路货物量分布

2.3.3 对问题三的具体分析

要求在关闭 DC9 站点，并且能够每日对站点网络进行动态分配，使得所有的包裹尽可能的正常流转，并且改变的线路数尽可能少，以及各条线路的工作负荷尽可能均衡。首先，我们在模型二的基础上引入新的决策变量，代表各路线是否开放，并且优化了问题二中的部分约束条件以及目标函数，引入货物总量的动态约束，建立了多目标动态规划模型，使用遗传算法进行求解，最终得到各路线每日货物量情况。

2.3.4 对问题四的具体分析

要求对该网络的不同物流场地及线路的重要性进行评价，并讨论新增物流场地的处理能力以及新增线路的运输能力。首先，有些网络在以前很火爆，但近期逐渐衰败，为了使模型具有时效性，我们选择在 2022 年 6 月到 2022 年 12 月期间

对各线路的货物运输总量、累计开启时间、最大运输能力、最长连续开启时间、最长连续关闭时间，五个方面进行统计，对各站点的连接线路个数、最大承载能力、最大发送能力、累计承载数量和累计发送数量五个方面进行统计，通过TOPSIS熵权法对站点和路线进行评价，之后根据预测结果以及评价结果，选择新增的场地以及其连接的线路。

三、模型假设

假设一：未记录的站点之间不存在运输情况

假设二：预测期间电商的环境趋于稳定

假设三：所给的数据与事实一致，不存在异常值

假设四：能够仅仅通过历史的货物量来预测未来的货物量

假设五：线路的最大运输能力为历史运输最大值

四、符号说明

序号	符号	符号说明	单位
1	$y_{ij}(t)$	第 i 站点到第 j 站点 在第 t 天的实际包裹 数量	件
2	$X_{ij}(t)$	第 i 站点到第 j 站点 在第 t 天的预测包裹 数量	件
3	M_{ij}	第 i 站点到第 j 站点 的历史最大包裹数量	件
4	$Z_{ij}(t)$	第 i 站点到第 j 站点 在第 t 天的包裹数量 是否改变	0-1
5	$K_{ij}(t)$	第 i 站点到第 j 站点 在第 t 天的是否连通	0-1
6	N_{ij}	原始条件下第 i 个站 点与第 j 个站点的连 通情况	0-1

五、模型的建立与求解

5.1 问题一的分析与求解

5.1.1 对问题的分析

要求建立线路货量的预测模型，对 2023-01-01 至 2023-01-31 期间每条线路每天的货量进行预测，并给出线路 DC14→DC10、DC20→DC35、DC25→DC62 的预测结果。首先，我们将所给的数据通过 Matlab 进行数据提取，得到各个路线每日的货物情况，再建立基于深度 AR 神经网络的预测模型，得到各路线在 2023-01-01 至 2023-01-31 期间的货物流通情况，总体思路流程图如下。




图 2 问题一思路流程图

5.1.2 数据处理与可视化分析

通过 Matlab 软件，我们得到每条路线每日货物量情况，其中 DC14→DC10、DC20→DC35、DC25→DC62 的历史物流流通情况如图。




图 3 2021-2022 年间各路线的物流量变化情况

从上图可知，在 2021 年（横坐标 365 之前），三条路线中仅有 DC20-DC35 有较大货物量通过，在 2022 年时 DC14-DC10 这条路线的货物量开始急剧增加，在 2022 年底都区域平稳，因此通过历史物流量来预测未来的物流量是有一定可行性的。

5.1.3 基于深度 AR 神经网络的货物量预测模型的建立与求解^[3]

我们将整理好的历史货物量数据，前 18 个月作为训练集，后 6 个月作为测试集。通过调试，我们发现普通 AR 时间序列的预测效果并不好。经过文献查阅，我们选择使用深度 AR 神经网络预测模型。

➤ Deep AR 神经网络的原理

与传统神经网络相比，深度 AR 神经网络采用循环模型。也就是说，之前的网络输出作为新的输入被传递到下一个时间步骤作为反馈。该模型的似然函数为固定分布，本文采用高斯似然 $\theta = (\mu, \sigma)$ ，用均值和方差对高斯似然进行参数化，即均值 μ 由 LSTM 网络中 h_i 和 t 的线性变换得到。方差 σ 为 h_i 和 t 由线性变换后的 softplus 函数约束得到。计算公式如下：

$$\mu = \varpi^T h + b \quad (1)$$

式中， w 和 b 分别为对应的权值矩阵和偏置项。

在训练阶段，给定时间序列和协变量，通过最大对数似然法得到模型参数。对应公式如下：

$$L = \sum_{i=1}^N \sum_{t=t_0}^T \log l(z | \theta(h)) \quad (2)$$

模型的训练和测试过程示意图如下图所示，其中模型的输入和输出用具体的值表示。




图 4 神经网络示意图

➤ 模型求解

通过 Deep AR 神经网络对测试集进行预测，得到各路线的平均误差值为百分之 12.44，其中平均误差的计算公式如下。

$$e_{ij} = \frac{\sum_{k=1}^{183} |X_{ijk} - \hat{X}_{ijk}|}{183} \quad (3)$$

其中 i, j 表示从第 i 个站点到第 j 个站点。

我们对各线路在 2023 年 1 月的每日货物量进行预测，得到每条路线每日预测货物量情况，其中 DC14→DC10、DC20→DC35、DC25→DC62 的预测结果如下表所示。

表 1 部分路线的预测结果

	DC14→DC10	DC20→DC35	DC25→DC62
2023-1-1	27548.99271	111.4164034	15747.40199

	DC14→DC10	DC20→DC35	DC25→DC62
2023-1-2	26694.05605	114.1395822	13113.47666
2023-1-3	26719.68571	179.7196803	10342.56679
2023-1-4	27246.58229	148.9454545	11382.72926
2023-1-5	28028.52723	129.7874554	6912.323811
2023-1-6	28814.78849	130.1971284	8327.843181
2023-1-7	28860.67994	193.7851814	12928.26066
2023-1-8	28230.65628	205.5163871	14028.88716
2023-1-9	27516.09074	214.4958912	11524.97437
2023-1-10	26886.44684	195.1730499	7525.30078
2023-1-11	26420.4041	241.200937	7574.322082
2023-1-12	26052.07544	197.7309559	8474.463287
2023-1-13	25646.81534	232.931811	10854.33339
2023-1-14	25095.56584	232.1666794	12963.17464
2023-1-15	25213.36253	204.0235615	8602.384617
2023-1-16	28446.57103	280.6640918	11546.10083
2023-1-17	40217.24985	281.8980338	11597.1
2023-1-18	65318.57239	300.8274666	8856.215978
2023-1-19	67849.33293	237.2527634	8002.034884
2023-1-20	41701.04043	244.4092566	15814.18784
2023-1-21	34711.98277	252.4385886	9094.151716
2023-1-22	34486.15423	315.1275694	4708.890421
2023-1-23	31864.67652	333.2965346	12248.50976
2023-1-24	30100.38022	244.5673821	8036.500525
2023-1-25	30836.2046	301.8774393	5717.901763
2023-1-26	35186.86478	317.0266645	8385.308316
2023-1-27	42538.62872	384.8117889	10347.59906
2023-1-28	48271.63966	406.0720329	7403.65634
2023-1-29	48686.54948	522.5748256	10825.10745
2023-1-30	59776.38322	562.0738172	10912.30062
2023-1-31	62849.58859	593.2686396	10236.02374

从上图可知，在 2023 年 1 月 31 号，DC14→DC10 路线上共有 62850 件货物、DC20→DC35 上共有 593 件货物、DC25→DC62 上共有 10236 件货物。这与我们整理出的各路线货物量变化趋势一致，符合实际情况。

5.2 问题二的分析与求解

要求在 DC5 站点关闭时，建立数学模型，使得所有包裹尽可能的正常流转，以及 DC5 关停前后变化的线路尽可能少，且保持各条线路的负荷尽可能均衡。首先，我们引入线路包裹数量作为决策变量，引入线路变化函数、工作负荷函数以及非正常流转天数作为目标函数，引入最大包裹数量约束、DC5 站点损坏约束，建立多目标优化模型，通过遗传算法进行求解，最终得到新的线路货物量分布。

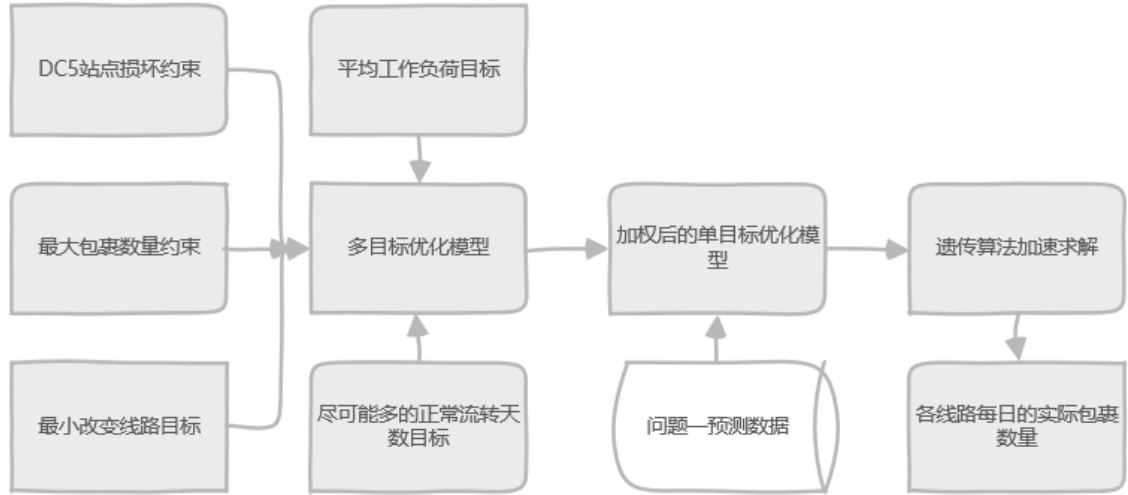


图 5 问题二思路流程图

5.2.1 多目标优化模型的建立

我们的目标 1 是令尽可能多的包裹正常流转，即：

$$\min \sum_{i=1}^n \sum_{j=1}^n (y_{ij}(t) - x_{ij}(t)) \quad (4)$$

其中，y 代表实际货物量，属于决策变量，x 为预测货物量，n 为站点个数，都属于常量。

我们的目标 2 是各条线路的负荷尽可能均衡，即：

$$\min \sum_{i=1}^n \sum_{j=1}^n \frac{y_{ij}(t)}{M_{ij}} \quad (5)$$

其中，M 为第 i 个站点到第 j 个站点的最大包裹数量。

我们的目标 3 是改变线路最少，我们引入 0-1 整型变量 Z，定义为：

$$Z_{ij}(t) = \begin{cases} 1, & \text{第 } i \text{ 站点到第 } j \text{ 站点的实际包裹数在第 } t \text{ 天发生变化} \\ 0, & \text{第 } i \text{ 站点到第 } j \text{ 站点的实际包裹数在第 } t \text{ 天不发生变化} \end{cases} \quad (6)$$

因此，目标函数 3 为：

$$\min \sum_{i=1}^n \sum_{j=1}^n Z_{ij}(t) \quad (7)$$

另外，各站点的物流量不能高于其历史最大包裹数量，即受到约束条件：

$$y_{ij}(t) \leq M_{ij} \quad (8)$$

同时，由于 DC5 路线的损坏，引出如下约束条件。

$$y_{5j}(t) = y_{i5}(t) = 0 \quad (9)$$

综上，我们建立的多目标优化模型为：

$$\begin{aligned} \min & \sum_{i=1}^n \sum_{j=1}^n (y_{ij}(t) - x_{ij}(t)) \\ \min & \sum_{i=1}^n \sum_{j=1}^n \frac{y_{ij}(t)}{M_{ij}} \\ \min & \sum_{i=1}^n \sum_{j=1}^n Z_{ij}(t) \\ s.t. & \begin{cases} y_{ij}(t) \leq M_{ij} \\ y_{5j}(t) = y_{i5}(t) = 0 \end{cases} \end{aligned} \quad (10)$$

根据目标的重要程度，我们将各目标标准化后依次添加权重 **【0.7,0.5,0.3】**，整理为新的单目标函数，即：

$$\min 0.7 \sum_{i=1}^n \sum_{j=1}^n \left(\frac{y_{ij}(t) - x_{ij}(t)}{x_{ij}(t)} \right) + 0.5 \sum_{i=1}^n \sum_{j=1}^n \frac{y_{ij}(t)}{M_{ij}} + 0.3 \sum_{i=1}^n \sum_{j=1}^n Z_{ij}(t) \quad (11)$$

为了加速求解效率，我们选择遗传算法来进行求解。

5.2.2 遗传算法的原理

与生物进化过程类似，遗传算法主要利用优胜劣汰的原则来选择群体，只有优秀的群体才能生存。遗传算法是一种基于适应度函数(或目标函数)的迭代过程，通过对个体群体进行遗传操作来实现群体中个体结构的重组。在这个过程中，群体个体(问题的解)被一代一代的优化，逐渐接近最优解。

与枚举法、启发式算法等传统优化方法不同，遗传算法作为一种自适应全局最优概率搜索算法，具有以下特点：

1. 遗传算法是一种自适应全局最优概率搜索算法。它具有自组织、适应和学习能力，具有鲁棒性；
2. 基于目标函数的评价信息搜索不需要目标函数的连续性和导数；
3. 可以同时优化多个解，具有隐式并行性；
4. 直接处理的对象是参数代码集，而不是问题参数本身。因此，它非常适用于求解高时间复杂度的问题。

为了实现遗传算法，我们必须掌握遗传算法中每个基本项对应于原始问题空间的具体含义。我们对一些生物术语在遗传算法中的具体含义进行了整理，整理结果如下：

- 基因:原问题空间中的解的元素；
- 染色体:染色体由一个或多个基因组成。一般来说，一条染色体对应于原始问题空间中的一个解；
- 适应度:目标函数空间中的值；

- 个体:个体由一组染色体唯一标识。一般来说,每个个体至少有两个基本属性:染色体和适应度。染色体唯一地决定了一个个体,适应度表示个体对环境的适应能力,即染色体决定的解所对应的目标函数的值;
- 群体:通常由多个个体组成一个群体。换句话说,一个总体代表原始问题空间中的多个解。

遗传算法的基本实现方法如下:

1. 根据具体问题确定可行解域,并确定编码方法。可行解域的每个解都可以用一个或多个数值字符串表示。
2. 度量每个溶液的质量都应该有一个基础,这个基础由一个称为适应度函数的函数表示,该函数通常由一个目标函数组成。
3. 确定进化参数的种群大小 M 、交叉概率 p_c 、突变概率 p_m 和进化终止条件。

综上所述,遗传算法的算法流程图如下。




图 6 遗传算法的流程图

5.2.3 模型求解

将问题一中预测的数据带入优化模型中,在 MATLAB 上通过遗传算法进行求解,得到各路线上的实际包裹数量,其中部分路线的包裹数量如下图。




图 7 DC22-DC4 路线上的理论与实际包裹数

从上图可知,由于 DC5 站点的停用,部分货物在 6 号、10、11 号等日期运到了 DC22-DC4 路线上,同理,有许多其他线路也有此情况。

我们总结所有货物量改变的线路,以及其对应的负荷程度,共得到 62 条线路货物量发生改变,其中根据符合程度大小排列,其中 10 条负荷程度较大线路,如下表所示。

表 2 平均负荷程度较大的 10 个路线

路线	每日平均负荷程度	累计增加包裹数量
22-4	20.99%	186517
46-10	20.75%	16338.5
22-62	20.59%	47964.2
28-14	20.58%	11973.4
20-4	20.39%	96957.3
59-35	20.29%	2116.26
19-62	20.00%	52395
25-8	19.71%	74822.3
28-62	19.47%	12997.7

从上图可知，路线的平均负荷率一般在百分之 20 附近波动，这与要求的各路线负荷率相平衡相符，说明了我们优化模型的有效性，同时本次一共导致 62 条线路发生改变，仅占 1049 条线路的百分之 6，符合改变线路尽可能少的要求。

5.2.4 优化模型合理性与灵敏度分析

我们在处理多目标问题时，人为的设置各目标的权重，但是在不同情况下，我们对不同目标的倾向程度不一定相同，因此，我们对目标的权重进行波动，得到最大负荷率随权重波动的结果如下表。

表 3 模型的灵敏度分析

权重波动 (%)	最大平均负荷程度	改变的线路个数
-10	25.99%	57
-5	23.75%	60
0	20.59%	62
5	18.22%	88
10	14.55%	104

合理性分析：从上表可知，随着权重的波动，改变线路的个数与最大平均负荷程度成反方向变化趋势，这与拥有多条可运输路线，能够减少每条路线的货物数量的事实情况相符，即我们的模型符合实际情况。

5.3 问题三的分析与求解

要求在关闭 DC9 站点，并且能够每日对站点网络进行动态分配，新增的路线最大值为原有路线的历史物流最大值的情况下，使得所有的包裹尽可能的正常流转，并且改变的线路数尽可能少，以及各条线路的工作负荷尽可能均衡。首先，我们在模型二的基础上引入新的决策变量，代表各路线是否开放，并且优化了问题二中的部分约束条件以及目标函数，建立了多目标动态规划模型，使用遗传算法进行求解，最终得到各路线每日货物量情况。总体思路流程图如下。

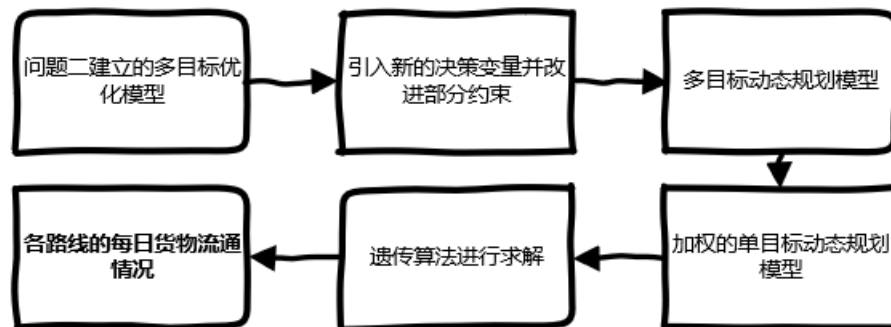


图 8 问题三思路流程图

5.3.1 多目标动态规划模型的建立

由于我们可以在每日决定是否开放新的路线进行货物运输，因此我们引入新的 0-1 型决策变量 K ，定义为：

$$K_{ij}(t) = \begin{cases} 1, \text{第}t\text{天站点}i\text{和}j\text{直接属于流通状态} \\ 0, \text{第}t\text{天站点}i\text{和}j\text{直接不属于流通状态} \end{cases} \quad (11)$$

因此，我们的目标函数 1：尽可能少的改变线路数可以表达为：

$$\min \sum_{i=1}^n \sum_{j=1}^m (K_{ij}(t) - N_{ij}) \quad (12)$$

其中， N 为原始情况下第 i 个站点与第 j 个站点的流通情况。

对于目标函数 2：各条线路上的工作负荷尽可能平衡，由于每条线路在关闭时最大物流量都为 0，不具有讨论意义，因此我们引入新的负荷公式：

$$w_{ij}(t) = \begin{cases} \frac{|Y_{ij}(t)|}{M_{ij}}, K_{ij}(t) = 1 \\ \text{不参与计算}, K_{ij}(t) = 0 \end{cases} \quad (13)$$

因此，目标函数 2 的表达式为：

$$\min \sum \sum \left(w_{ij}(t) - \frac{\sum \sum w_{ij}(t)}{\sum \sum K_{ij}(t)} \right) \quad (14)$$

对于目标函数 3：不正常流转的日期尽可能少，即每日的理论运输量与实际运输量的差值尽可能少，于是目标函数 3 的表达式为：

$$\min \sum_{i=1}^n \sum_{j=1}^m (y_{ij}(t) - x_{ij}(t)) \quad (15)$$

考虑到当某条路线关闭时，该路线上的实际运输量应该为 0，我们引入线路开关约束：

$$Y_{ij} = 0, \text{if } K_{ij} = 0 \quad (16)$$

考虑到不同线路上存在着不同的最大货物流量的限制，我们引入最大货物量约束，即：

$$Y_{ij}(t) \leq M_{ij} \quad (17)$$

其中，对于新开设的路线，其最大货物流量为已有线路的最大值。

考虑到 DC9 站点损坏，我们引入站点损坏约束：

$$K_{9j}(t) = K_{j9}(t) = 0 \quad (18)$$

最后，引入动态约束：每个时刻的累计运输量不应该大于总货物累计量，即货物总量约束：

$$\sum_{k=1}^t \sum_{i=1}^n \sum_{j=1}^m Y_{ij}(k) - \sum_{k=1}^{t-1} \sum_{i=1}^n \sum_{j=1}^m X_{ij}(k) \leq \sum_{i=1}^n \sum_{j=1}^m X_{ij}(t) \quad (19)$$

综上，我们构建了多目标动态规划模型，对于 3 个目标，我们分别赋予【0.7, 0.5, 0.3】的权重，将其转变为单目标动态规划模型，即：

$$\begin{aligned} \min & 0.7 * \sum_{i=1}^n \sum_{j=1}^m (K_{ij}(t) - N_{ij}) + 0.5 * \sum \sum \left(w_{ij}(t) - \frac{\sum_{i=1}^m \sum_{j=1}^m w_{ij}(t)}{\sum_{i=1}^m \sum_{j=1}^m K_{ij}(t)} \right) + \\ & 0.3 * \sum_{i=1}^n \sum_{j=1}^m (y_{ij}(t) - x_{ij}(t)) \\ s.t. & \begin{cases} K_{9j}(t) = K_{j9}(t) = 0 \\ Y_{ij} = 0, \text{ if } K_{ij} = 0 \\ Y_{ij}(t) \leq M_{ij} \\ \sum_{k=1}^t \sum_{i=1}^n \sum_{j=1}^m Y_{ij}(k) - \sum_{k=1}^{t-1} \sum_{i=1}^n \sum_{j=1}^m X_{ij}(k) \leq \sum_{i=1}^n \sum_{j=1}^m X_{ij}(t) \end{cases} \end{aligned} \quad (20)$$

5.3.2 基于遗传算法的动态规划模型求解^[4]

将数据带入问题三的动态分析模型中，在 MATLAB 软件上通过神经网络算法进行求解，得到各路线每日货物量运输情况，1 月份一共新增 4 条线路，新增的路线如下表所示：

表 4 一月份新增线路

新增路线	新增时间	平均通过货物量
22-2	1	5
62-6	1	9
14-2	1	3
8-11	1	2

从上表可知，新增的路线都在 1 号，这与月初 22、62、14、8 四个站点所有线路的预测货物量均处于历史最大值有关，此时无法通过其他线路来完成 9 号站点的货物量需求，因此开设了 4 条新的线路。这也体现了我们的优化模型对新建站点的惩罚力度是非常大的。

此时，一共有 117 条线路货物量发生改变，其中平均负荷最高的十个站点如下表。

表 5 关闭 DC9 后平均负荷最高的 10 条路线

路线	每日平均负荷程度	平均增加包裹数量
65-10	2.96%	7
60-3	2.95%	9
60-64	2.92%	5
53-65	2.91%	2
60-40	2.88%	6
10-64	2.85%	4
19-64	2.84%	5
73-64	2.84%	7
17-64	2.84%	4

从上表可知，我们的模型能够较好的保持各路线负荷均衡，同时增加的 117 条路线在总路线基数下也处于可以接受的范围。

5.3.3 改进后的优化模型灵敏度分析

我们通过不断波动权重，观察其新增路线、最大负荷程度的变化情况，改进的优化模型灵敏度分析结果如下图。




图 9 动态规划模型的灵敏度分析

从上图可知，我们的模型在波动为百分之 10 以内具有相当高的鲁棒性，最大负荷程度以及新增的线路不发生变化，当波动为百分之 15 时，新增线路变为 5 条，最大负荷程度也降低到百分之 2.75。这也说明如果我们想要改变目标函数的重要程度，需要以百分之 15 为基础进行改动。

5.4 问题四的分析与求解

要求对该网络的不同物流场地及线路的重要性进行评价，并讨论新增物流场地的处理能力以及新增线路的运输能力。首先，有些网络在以前很火爆，但近期逐渐衰败，为了使模型具有时效性，我们选择在 2022 年 6 月到 2022 年 12 月期间对各线路的货物运输总量、累计开启时间、最大运输能力、最长连续开启时间、最长连续关闭时间，五个方面进行统计，对各站点的连接线路个数、最大承载能力、最大发送能力、累计承载数量和累计发送数量五个方面进行统计，通过 TOPSIS 熵权法对站点和路线进行评价，之后根据预测结果以及评价结果，选择新增的场地以及其连接的线路，总体思路流程图如下。

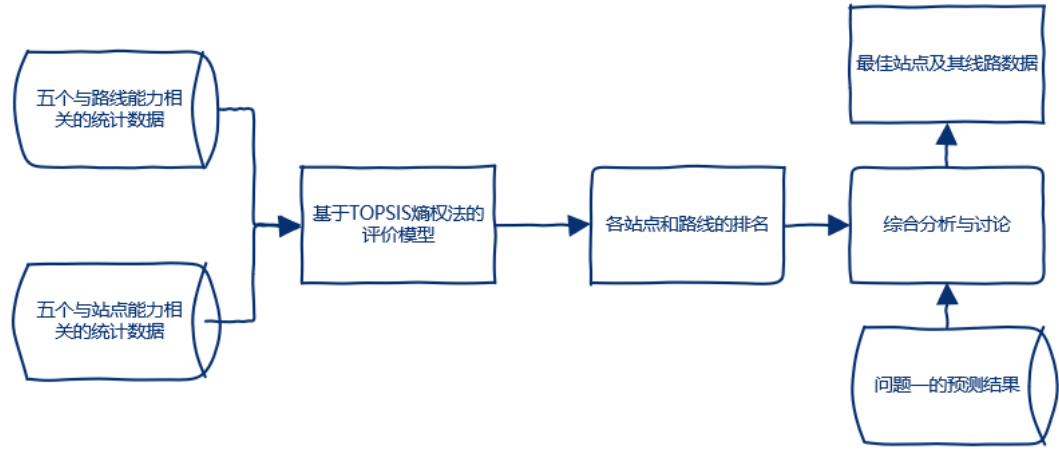


图 10 问题四的思路流程图

5.4.1 数据整理

我们整理在 2022 年 6 月到 2022 年 12 月期间各线路的货物运输总量、累计开启时间、最大运输能力、最长连续开启时间、最长连续关闭时间，分别用 Q1 到 Q5 表示。得到的部分结果如下表。

表 6 路线的部分特征统计结果

路线	Q1	Q2	Q3	Q4	Q5
18-14	178079	102	19547	84	37
8-10	605968	131	23091	54	49
26-10	715851	144	10954	75	25
----	----	----	----	----	----
53-8	311513	115	10048	76	22

上表显示了各线路的统计结果，从上表可知，不同线路的特征有明显区别，即，通过上述指标评价线路的好坏是合理的。

同理，将各站点的连接线路个数、最大承载能力、最大发送能力、累计承载数量和累计发送数量五个方面的数据进行整理，用 P1 到 P5 表示。

5.4.2 基于 TOPSIS 熵值法的评价模型原理

TOPSIS 法(近似理想排序法)是系统工程中的一种多目标决策方法，在有限方案中找出最优方案和最坏方案。当可行方案最接近最优方案且远离最坏方案时，该方案的向量集即为最优影响评价指标。

TOPSIS 法是一种综合指标评价方法，不同于模糊综合评价法和层次分析法(AHP)。它具有较强的主观性，不需要目标函数，也不需要通过相应的检验，即限制要求大大降低，使适用范围更广。

首先，建立归一化矩阵对整理的数据进行标准化。标准化公式如下：

$$Z_{ij} = \frac{Q_{ij}}{\sqrt{\sum_{i=1}^m Q_{ij}^2}} \quad (i = 1, \dots, n; j = 1, \dots, 5) \quad (21)$$

其中， Q_{ij} 代表第 i 个数据第 j 个指标的值。

通过上诉法得到 z 矩阵，选取各指标的最大值作为最优向量：

$$Z_i^+ = \max |Z_{ij}| \quad (i = 1, \dots, n) \quad (22)$$

对于最差向量也是如此。

然后计算各指标与最优向量的欧氏距离：

$$D^+ = \sqrt{\sum_{i=1}^n (Z_{ij} - Z_j^+)^2} \quad (23)$$

对于最劣向量的距离也是如此。

最后，得到与最优值的相对接近程度：

$$W_i = \frac{D_i^-}{D_i^+ + D_i^-} \quad (24)$$

5.4.3 评价模型的求解

通过文献研究，我们认为路线中货物运输总量 Q1、累计开启时间 Q2、最大运输能力 Q3、最长连续开启时间 Q4 为正向指标。最长连续关闭时间 Q5 属于负向指标。

在 SPSSPRO 中运行，得到线路各指标的权重如表所示。

表 7 线路的指标权重计算结果

熵权法			
指标	信息熵 e	信息效用价值 d	权重 (%)
Q1	0.976	0.024	7.597
Q2	0.951	0.049	12.51
Q4	0.907	0.093	31.771
Q5	0.949	0.051	21.941
Q3	0.928	0.072	26.88

从上表可知，指标 Q4 最长连续开启时间的信息效用价值最高，权重也最为重要，达到了百分之 31.77，而总的货物运输总量 Q1 信息效用价值最小，权重也只有百分之 7.59

我们认为站点中连接线路个数 P1、最大承载能力 P2、最大发送能力 P3、累计承载数量 P4 和累计发送数量 P5 都为正向指标。

在 SPSSPRO 中运行，得到站点各指标的权重如表所示。

表 8 站点各指标的权重计算结果

指标	信息熵 e	信息效用价值 d	权重 (%)
P5	0.966	0.016	5.457
P2	0.942	0.059	14.22
P1	0.931	0.095	29.242

指标	信息熵 e	信息效用价值 d	权重 (%)
P5	0.929	0.051	25.877
P3	0.914	0.072	25.486

从上表可知，站点连接线路个数 P1 最为重要，权重为百分之 29.24。
最终得出的物流场地以及线路的前 5 名如下表。

表 9 线路和站点的 TOPSIS 评分前 5 名

排名	线路	站点
1	14-8	DC10
2	17-10	DC7
3	22-4	DC8
4	36-10	DC4
5	23-4	DC62

从上表可知，线路的前三名为 14-8、17-10、22-4，站点的前三名为 DC10、DC7、DC8。

5.4.4 新增站点及线路的讨论

根据评价模型，线路 14-8、17-10 属于重点线路，观察问题一的预测结果，我们发现站点 DC8 和 DC10 对包裹的接收能力很强，因此我们可以在 DC8 与 DC10 附近建立新的站点，同时与其相连通，新站点的处理能力需要与二者相符，新增的路线运输能力为二者最大运输线路的平均值，以便于货物在二者间进行流通。

5.4.5 网络的鲁棒性分析

我们在 DC8 与 DC10 站点附近建立的新站点主要目的是使应急情况下能够快速把货物运输到 DC8 与 DC10 两个重要站点。

通过对问题一的分析，我们的模型准确率在百分之 85 左右，当预测的物流量与实际物流量产生偏差时，我们的新站点能够及时的对多出的货物进行缓冲，并及时的将货物送到两个重点站点中。

因此，即便预测结果有一定的误差，我们的网络也能稳定的运行，有着极高的鲁棒性。

六、模型的评价和推广

6.1 模型的优点

- 本文对问题的求解有合理的猜想，并进行了多种算法的搭配使用。
- 本文对优化模型进行了灵敏度检验，使结论更有可信度
- 图文并茂。有流程图，结果图，思维导图等，可视化强。
- 多种软件相互配合，取长补短，本文通过 Origin, PPT, Matlab、Python 等软件，进行问题求解和结果可视化。
- 条理清晰，逻辑缜密，模型简单易懂，在求解的过程中逐步完善理论。

6.2 模型的缺点

- 第一问中的预测算法耗时较长，需要将所有路线提取成单维的数据再进行预测，时效性不高。

- 第四问中的新站点建立无理论依据支撑，处理能力和运输能力无明确计算公式，普适性不高。

6.3 模型的推广

6.3.1 横向推广

我们的模型除了能够在电商物流网络的应急优化中起到不错的作用，还能在药品配送调度等场景下起作用。

6.3.2 纵向推广

我们的模型不但能够在单向运输的情况下进行结构优化，对于双向网络，我们的模型也能起到不错的效

其他服务请联系q1423801308

七、参考文献

- [1] 补偿最小二乘估计精化 AR(p)的变形建模与预测[J]. 高宁;崔希民;王果;张玲;卢立托.工程勘察,2013(01)
- [2] 补偿最小二乘在 GPS 高程拟合中的应用及平滑参数的选取[J]. 徐长海;吴良才;高宁;高彩云.矿山测量,2009(01)
- [3] 基于遗传算法的 5G 频率选择表面形状优化方法[J]. 晋刚;何志豪;王英俊.华南理工大学学报(自然科学版),2021(11)
- [4] 基于遗传算法的道路安定极限优化求解方法[J]. 宋修广;张营超;庄培芝;杨鹤;张海凤;王娟.山东大学学报(工学版),2021(05)
- [5] 基于改进 TOPSIS 模型的吉林省水资源承载力时空演变分析[J]. 侯岳;李治军;王华凡;黄佳俊.人民珠江
- [6] 基于熵权 TOPSIS 模型的辽宁省区水资源承载力评价研究[J]. 任博;曹永强;李可欣;杨雪婷;周姝含;赵慧.人民珠江

八、 附录

AR 时间序列核心代码

%-----由于时间序列有不平稳趋势，进行两次差分运算，消除趋势性
-----%

```
for i=2:96
    Yt(i)=P(i)-P(i-1);
end
for i=3:96
    L(i)=Yt(i)-Yt(i-1);
end
L=L(3:96);
Y=L(1:88);
```

```
%画图
figure;
plot(P);
title('原数据序列图');
hold on;
pause
plot(Y,'r');
title('两次差分后的序列图和原数对比图');
pause
```

%-----对数据标准化处理-----

-----%

%处理的算法：(data - 期望)/方差

```
Ux=sum(Y)/88          % 求序列均值
```

```
yt=Y-Ux;
```

```
b=0;
```

```
for i=1:88
```

```
    b=yt(i)^2/88+b;
```

```
end
```

```
v=sqrt(b)          % 求序列方差
```

```
Y=yt/v;          % 标准化处理公式
```

```
f=F(1:88);
```

```
t=1:88;
```

```
%画图
```

```
figure;
```

```
plot(t,f,t,Y,'r')
```

```
title('原始数据和标准化处理后对比图');
```

```
xlabel('时间 t'),ylabel('油价 y');
```

```
legend('原始数据 F ','标准化后数据 Y ');
```

```
pause
```

%-----对数据标准化处理-----

-----%

```

%-----检验预处理后的数据是否符合 AR 建模要求，计算自相关和
偏相关系数-----%

%-----计算自相关系数-----%
R0=0;
for i=1:88
    R0=Y(i)^2/88+R0; %标准化处理后的数据的方差
end

for k=1:20

    %R 协方差
    R(k)=0;
    for i=k+1:88
        R(k)=Y(i)*Y(i-k)/88+R(k);
    end
end
x=R/R0          %自相关系数 x = 协方差/方差

%画图
figure;
plot(x)
title('自相关系数分析图');
pause
%-----计算自相关系数-----%

%-----解 Y-W 方程，其系数矩阵是 Toeplitz 矩阵(多普里兹矩阵)。求
得偏相关函数 X-----

X1=x(1);
X11=x(1);
B=[x(1) x(2)]';
x2=[1 x(1)];
A=toeplitz(x2);
X2=A\B          %x=a\b 是方程 a*x =b 的解
X22=X2(2)

B=[x(1) x(2) x(3)]';
x3=[1 x(1) x(2)];
A=toeplitz(x3);
X3=A\B
X33=X3(3)

B=[x(1) x(2) x(3) x(4)]';
x4=[1 x(1) x(2) x(3)];
A=toeplitz(x4);
X4=A\B
X44=X4(4)

```

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5)]'$;
 $x5=[1 \ x(1) \ x(2) \ x(3) \ x(4)]$;
 $A=\text{toeplitz}(x5)$;
 $X5=A \setminus B$
 $X55=X5(5)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6)]'$;
 $x6=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5)]$;
 $A=\text{toeplitz}(x6)$;
 $X6=A \setminus B$
 $X66=X6(6)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7)]'$;
 $x7=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6)]$;
 $A=\text{toeplitz}(x7)$;
 $X7=A \setminus B$
 $X77=X7(7)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8)]'$;
 $x8=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7)]$;
 $A=\text{toeplitz}(x8)$;
 $X8=A \setminus B$
 $X88=X8(8)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9)]'$;
 $x9=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8)]$;
 $A=\text{toeplitz}(x9)$;
 $X9=A \setminus B$
 $X99=X9(9)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9) \ x(10)]'$;
 $x10=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9)]$;
 $A=\text{toeplitz}(x10)$;
 $X10=A \setminus B$
 $X1010=X10(10)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9) \ x(10) \ x(11)]'$;
 $x11=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9) \ x(10)]$;
 $A=\text{toeplitz}(x11)$;
 $X101=A \setminus B$
 $X1111=X101(11)$

$B=[x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9) \ x(10) \ x(11) \ x(12)]'$;
 $x12=[1 \ x(1) \ x(2) \ x(3) \ x(4) \ x(5) \ x(6) \ x(7) \ x(8) \ x(9) \ x(10) \ x(11)]$;
 $A=\text{toeplitz}(x12)$;
 $X12=A \setminus B$
 $X1212=X12(12)$

$X=[X11 \ X22 \ X33 \ X44 \ X55 \ X66 \ X77 \ X88 \ X99 \ X1010 \ X1111 \ X1212]$


```

%-----解 Y-W 方程，得偏相关函数 X-----
-----%
figure;
plot(X);
title('偏相关函数图');
pause

%-----根据偏相关函数截尾性，初判模型阶次为 5。用最小二乘法估计参数,计算
10 阶以内的模型残差方差和 AIC 值，应用 AIC 准则为模型定阶-----%
S=[R0 R(1) R(2) R(3) R(4)];
G=toeplitz(S);
%inv(G)返回 G 的反函数
W=inv(G)*[R(1:5)]' % 参数 W(i) 与 X5 相同 G*W = [R(1:5)]'

K=0;
for t=6:88
    r=0;
    for i=1:5
        r=W(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(5)=K/(88-5) % 5 阶模型残差方差 0.4420

K=0;T=X1;
for t=2:88
    at=Y(t)-T(1)*Y(t-1);
    K=(at)^2+K;
end
U(1)=K/(89-1) % 1 阶模型残差方差 0.6954

K=0;T=X2;
for t=3:88
    r=0;
    for i=1:2
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(2)=K/(88-2) % 2 阶模型残差方差 0.6264

K=0;T=X3;
for t=4:88
    r=0;
    for i=1:3
        r=T(i)*Y(t-i)+r;
    end

```

```

    at= Y(t)-r;
    K=(at)^2+K;
end
U(3)=K/(88-3)          % 3 阶模型残差方差 0.5327

```

```

K=0;T=X4;
for t=5:88
    r=0;
    for i=1:4
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(4)=K/(88-4)          % 4 阶模型残差方差 0.4751

```

```

K=0;T=X6;
for t=7:88
    r=0;
    for i=1:6
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(6)=K/(88-6)          % 6 阶模型残差方差 0.4365

```

```

K=0;T=X7;
for t=8:88
    r=0;
    for i=1:7
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(7)=K/(88-7)          % 7 阶模型残差方差 0.4331

```

```

K=0;T=X8;
for t=9:88
    r=0;
    for i=1:8
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(8)=K/(88-8)          % 8 阶模型残差方差 0.4310

```

```

K=0;T=X9;

```

```

for t=10:88
    r=0;
    for i=1:9
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(9)=K/(88-9)          %9 阶模型残差方差 0.4297

K=0;T=X10;
for t=11:88
    r=0;
    for i=1:10
        r=T(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
    K=(at)^2+K;
end
U(10)=K/(88-10)        % 10 阶模型残差方差 0.4317

U=10*U
for i=1:10
    AIC2(i)=88*log(U(i))+2*(i)    % AIC 值分别为: 172.6632 165.4660 153.2087
145.1442 140.7898 141.6824 142.9944 144.5601 146.3067 148.7036
end
%-----取使 AIC 值为最小值的阶次, 判断模型阶次为 5。用最小二乘法估计参数-----%

%-----检验 {at} 是否为白噪声。求 {at} 的自相关系数, 看其是否趋近于零-----%
C=0;K=0;
for t=7:88
    at=Y(t)-W(1)*Y(t-1)-W(2)*Y(t-2)-W(3)*Y(t-3)-W(4)*Y(t-4)-W(5)*Y(t-5)+Y(6)-
W(1)*Y(5)-W(2)*Y(4)-W(3)*Y(3)-W(4)*Y(2)-W(5)*Y(1);
    at1=Y(t-1)-W(1)*Y(t-2)-W(2)*Y(t-3)-W(3)*Y(t-4)-W(4)*Y(t-5)-W(5)*Y(t-6);
    C=at*at1+C;
    K=(at)^2+K;
end
p=C/K          %若 p 接近于零, 则 {at} 可看作是白噪声
%-----{at} 的自相关系数,趋近于零, 模型适用-----%
%-----AR(5)模型方程为-----%
% X(t)=W(1)*X(t-1)-W(2)*X(t-2)-W(3)*X(t-3)-W(4)*X(t-4)-W(5)*X(t-5)+at
(at=0.4420)

```

```

%-----后六年的数据 进行预测和效果检验-----
%

%-----单步预测 预测当前时刻后的六个数据-----
%
XT=[L(84:94)];
for t=6:11
    m(t)=0;
    for i=1:5
        m(t)=W(i)*XT(t-i)+m(t);
    end
end

m=m(6:11);

%-----预测值进行反处理-----%
m(1)=Yt(90)+m(1);      %一次反差分
z1(1)=P(90)+m(1);      %二次反差分
m(2)=Yt(91)+m(2);
z1(2)=P(91)+m(2);
m(3)=Yt(92)+m(3);
z1(3)=P(92)+m(3);
m(4)=Yt(93)+m(4);
z1(4)=P(93)+m(4);
m(5)=Yt(94)+m(5);
z1(5)=P(94)+m(5);
m(6)=Yt(95)+m(6);
z1(6)=P(95)+m(6);
z1          % 单步预测的向后 6 个预测值:z1= 13.9423
13.4101  13.3588  12.9856  13.2594  12.9552

%-----绘制数据模型逼近曲线-----%
for t=6:88
    r=0;
    for i=1:5
        r=W(i)*Y(t-i)+r;
    end
    at= Y(t)-r;
end

figure;
for t=6:88
    y(t)=0;
    for i=1:5
        y(t)=W(i)*Y(t-i)+y(t);
    end
    y(t)=y(t)+at;
end

```

```

    y(t)=Yt(t+1)-y(t);
    y(t)=P(t+1)-y(t);
end
plot(y,'r-*');          % 样本数据模型逼近曲线
hold on;
plot(91:96,z1,'r-*');
hold on;
plot(P,'--');           % 原样本曲线
title('AR(5)模型样本逼近预测曲线');
pause
%-----绘制数据模型逼近曲线-----%

%-----预测误差分析-----%
%-----计算单步预测绝对误差-----%
D=[13.70 13.66 13.27 13.56 13.14 14.19];
for i=1:6
    e1(i)=D(i)-z1(i);
    PE1(i)=(e1(i)/D(i))*100;
end
e1                                % 单步预测的绝对误差 e1 = -0.2423  0.2499  -
0.0888  0.5744  -0.1194  1.2348
PE1

%-----单步预测平均绝对误差-----%
mae1=sum(abs(e1))/6                % mae1 = 0.2681

%-----单步预测平均绝对百分比误差-----%
MAPE1=sum(abs(PE1))/6

%-----绘制预测结果和实际值的比较图-----%
figure;
plot(1:6,D,'-+');
hold on;
plot(z1,'r-*');
title('向前一步预测值和实际值对比图');
hold off;
pause
%-----单步预测 预测当前时刻后的六个数据-----%
%-----%

%-----多步预测 目的是向前六步预测-----%
%-----%
Xt=[ Y(84) Y(85) Y(86) Y(87) Y(88)];    %取当前时刻之前的 6 个数据

Z(1)=W(1)*Xt(5)+W(2)*Xt(4)+W(3)*Xt(3)-W(4)*Xt(2)-W(5)*Xt(1)

```

```

%-----求向前 1 步的预测值
%预测步数小于 5 时
for l=2:5
    K(l)=0;
    for i=1:l-1
        K(l)=W(i)*Z(l-i)+K(l);
    end
    G(l)=0;
    for j=1:5
        G(l)=W(j)*Xt(5+l-j)+G(l);
    end
    Z(l)=K(l)+G(l);
end
%预测步数大于 5 时（向前 6 步预测）
for l=6:6
    K(l)=0;
    for i=1:5
        K(l)=W(i)*Z(l-i)+K(l);
    end
    Z(l)=K(l);
end

%----预测值进行反标准化处理
r=Z*v+Ux           % 0.0581  0.0844  0.0156  0.0319  0.0632  0.0652
r(1)=Yt(90)+r(1);   %一次反差分
z(1)=P(90)+r(1)     %二次反差分
for i=2:6
    r(i)=r(i-1)+r(i);
    z(i)=z(i-1)+r(i)
end

%----- 预测误差分析 ----- %
%-----计算绝对误差和相对误差
D=[13.70 13.66 13.27 13.56 13.14 14.19 ];    % 预测值 z=14.0281  13.9606
13.9087 13.8887 13.9318 14.0403
for i=1:6
    e6(i)=D(i)-z(i);
    PE6(i)=(e6(i)/D(i))*100;
end
e6           % 多步预测的绝对误差 e = -0.3281  -0.3006  -
0.6387 -0.3287 -0.7918  0.1497
PE6          % 多步预测的相对误差
1-abs(PE6)   % 准确率

%-----多步预测平均绝对误差
mae6=sum(abs(e6))/6

```